


## Problem z przerabiania obrazu na wektor

Mając długi wektor analizujemy dany piksel biorąc jego sąsiedztwo z lewej i prawej strony, nie bacząc na to co jest powyżej i poniżej. Problem można rozwiązać stosując tensory (np zestaw wektorów odzwierciedlających po jednym z kanałów RGB obrazu)

## Konwolucja

Jest to przemnożenie macierzy przez zadane jądro (kernel, filter). Np:



Pozostałe pola Convolved Feature otrzymuje się poprzez przesuwanie jądra po obrazie. Jądro może być inne na każdej warstwie i w każdej epoce.

Kernele i ich zastosowania:

| Operation                              | Kernel $\omega$  | Image result $g(x,y)$ |
|--|--|-----------------------|
| Identity                               | $\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$              |                       |
| Edge detection                         | $\begin{bmatrix} 1 & 0 & -1 \\ 0 & 0 & 0 \\ -1 & 0 & 1 \end{bmatrix}$            |                       |
| Sharpen                                | $\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$          |                       |
| Gaussian blur 3 x 3<br>(approximation) | $\frac{1}{16} \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$ |                       |

## Zastosowania

- Wykrywanie wzorców
- Poprawianie jakości obrazu

- Zagłuszanie obrazu

## Co zrobić jak mamy na wejście obraz? (Wiele kanałów)

Dla każdego z kanału kolorów liczy się konwolucję, następnie sumuje się każdą konwolucję do jednej macierzy + potencjalny bias

## Kernel size

Jaki może być maksymalny rozmiar macierzy konwolucji? Może być równy na przykład rozmiarom obrazka lecz nie jest to robione ze względów następujących:

- tracimy możliwość wyodrębnienia lokalnych cech w obrazie na bazie których mode może poczynić klasyfikację.
- O wiele bardziej jest zwiększona złożoność obliczeniowa operacji dla takiego jądra konwolucji
- Utracenie informacji przestrzennej. Obraz byłby traktowany za każdym razem jako pojedyncza jednostka, co by się źle przełożyło na uczenie modelu.

Najczęściej stosuje się konwolucje o rozmiarach 1x1, 3x3, 5x5.

## Właściwości konwolucji

- Padding: dodanie zer dookoła wejściowej macierzy (z macierzy 6x6 robimy macierz 8x8)
- strides: rozmiar kroku w przejściu

## Wzór na wyjście z danej konwolucji

$$\text{output size} = \left\lfloor \frac{(\text{input size}) + 2 * \text{padding} - (\text{kernel size} - 1) - 1}{\text{stride}} + 1 \right\rfloor$$

## Dilation rate

Jest to wskaźnik o ile ma się przesuwac każdy składnik kernela po np obrazie Przykładowe zastosowanie:

- Dilation rate pozwala zwiększyć pole widzenia filtru bez konieczności zwiększania jego rozmiaru. To pozwala sieci lepiej rozumieć większe konteksty bez znacznego zwiększania liczby parametrów.
- Umożliwia przetwarzanie obrazów przy zachowaniu ich oryginalnej rozdzielczości, co jest przydatne w zadaniach takich jak segmentacja obrazów.

## Pooling

Operacja mająca na celu zredukować wymiarowość danych przy zachowaniu ważności danych. Główne cechy:

- sieć jest mniej wrażliwa na przesunięcia w danych wejściowych
- redukcja wymiarowości

## Average pooling

Oblicza wartość średnią z określonego obszaru danych wejściowych. Na przykład, w obszarze 2x2, average pooling będzie średnią z czterech wartości.

### Max pooling

Max pooling polega na wybraniu maksymalnej wartości z określonego obszaru danych wejściowych. Na przykład, w obszarze 2x2, max pooling wybiera największą wartość z tych czterech.